

INTELIGÊNCIA ARTIFICIAL E A ERA DA PERSONALIZAÇÃO: COMO A IA ESTÁ TRANSFORMANDO A EXPERIÊNCIA DO USUÁRIO

LUIZ FERNANDO D. PEDROZO – luizfernandodp1103@gmail.com

FACULDADE GALILEU

Resumo: *Nos últimos anos, a inteligência artificial (IA) tem desempenhado um papel fundamental na transmutação da experiência do usuário em diversos contextos. Este artigo busca explorar o impacto da IA na personalização, examinando como ela tem sido aplicada para criar experiências mais relevantes e individualizadas. Inicialmente, apresentamos os conceitos básicos de inteligência artificial e a importância da personalização na interação entre humanos e sistemas digitais. Em seguida, discutimos casos de uso de IA em proposições de produtos e serviços, plataformas de mídia e divertimento, assistentes virtuais e sistemas de suporte à decisão. Também abordamos os desafios e considerações éticas da personalização usando inteligência artificial, como a proteção dos dados do usuário, tendências algorítmicas e transparência dos sistemas. Por fim, discutimos as tendências futuras nesse espaço e a importância do envolvimento do usuário ao configurar a personalização. Por meio dessa análise, destacamos o potencial da inteligência artificial para transformar a experiência do usuário, bem como os desafios e responsabilidades que acompanham esse processo.*

Palavras-chave: *Inteligência Artificial; Experiência do usuário; Personalização.*

ARTIFICIAL INTELLIGENCE AND THE ERA OF PERSONALIZATION: HOW AI IS TRANSFORMING THE USER EXPERIENCE

Abstract: *In recent years, artificial intelligence (AI) has played a key role in transmuting the user experience in various contexts. This article seeks to explore AI's impact on personalization, examining how it has been applied to create more relevant and individualized experiences. Initially, we present the basic concepts of artificial intelligence and the importance of personalization in the interaction between humans and digital systems. We then discuss AI use cases in product and service propositions, entertainment and media platforms, virtual assistants and decision support systems. We also address the challenges and ethical considerations of personalization using artificial intelligence, such as protecting user data, algorithmic biases, and systems transparency. Finally, we discuss future trends in this space and the importance of user engagement when setting up personalization. Through this analysis, we highlight the potential of artificial intelligence to transform the user experience, as well as the challenges and responsibilities that accompany this process.*

Keywords: *Artificial intelligence; User experience; Customization.*

1. INTRODUÇÃO

Nos últimos anos, a inteligência artificial (IA) consolidou-se como uma das principais inovações tecnológicas do século XXI, provocando mudanças significativas em diversos setores da sociedade. Desde a automação de tarefas costumeiros até a análise de grandes volumes de dados, a IA mostrou um imenso potencial para transformar a maneira como interagimos com o mundo ao nosso redor. Nesse contexto, a personalização tornou-se um elemento-chave na busca por uma experiência de usuário cada vez mais satisfatória e atrativa.

A personalização é uma necessidade cada vez mais presente na sociedade atual. Com a crescente quantidade de informação disponível e os progressos tecnológicos que permitem acessá-la de forma rápida e fácil, o usuário moderno tornou-se mais exigente e busca experiências personalizadas que atendam às suas necessidades individuais. Seja navegando em plataformas de streaming, comprar produtos online ou interagir com assistentes virtuais. Espera-se que a tecnologia seja adaptada às tendências e características de cada pessoa.

Nesse sentido, a inteligência artificial emerge como uma ferramenta fundamental para a criação dessas experiências personalizadas. Por meio do uso de algoritmos avançados e técnicas de aprendizado de máquina, a IA pode analisar grandes quantidades de dados e extrair insights relevantes sobre os usuários, permitindo a adaptação de produtos, serviços e de conteúdos de acordo com suas preferências individuais. Essa personalização pode ocorrer em diversos níveis, desde recomendações de conteúdo, até a criação de interfaces interativas e adaptativas.

No entanto, apesar do grande potencial da inteligência artificial para transformar a experiência do usuário por meio da personalização, ainda existem desafios a serem enfrentados. Dentre eles, destaca-se a necessidade de compreender como a IA pode ser aplicada de forma eficiente e ética, garantindo benefícios reais para os usuários sem comprometer a privacidade e a segurança das informações. Além disso, é importante investigar como a personalização afeta a forma como os indivíduos percebem a experiência do usuário, levando em consideração fatores como a satisfação, engajamento e fidelização.

Portanto, diante desse cenário desafiador e promissor, o objetivo deste trabalho é analisar e entender como a inteligência artificial pode mudar a experiência do usuário

por meio da personalização. Serão examinados os últimos avanços em inteligência artificial e suas aplicações práticas no campo da personalização, bem como os desafios enfrentados ao fazê-lo. A importância da ética e da privacidade será enfatizada ao desenvolver sistemas personalizados para garantir que os usuários se sintam seguros. Além disso, tentamos explorar a percepção e o impacto da personalização na experiência do usuário, identificando benefícios e possíveis consequências negativas. Com base nessa premissa, este trabalho visa a elaboração de um modelo de análise sentimental baseada em um conjunto pré-treinado de dados que analisará avaliações de filmes classificadas como positivas ou negativas. Essa análise faz parte da estratégia de empresas para a personalização da experiência do usuário. Ao final do modelo, mostrarei insights e recomendações para futuros modelos.

2. INTELIGÊNCIA ARTIFICIAL

2.1 – Conceitos de inteligência artificial

A Inteligência Artificial (IA) é um campo que combina ciência da computação e conjuntos de dados robustos para permitir a solução de problemas. Abrange subcampos de aprendizado de máquina e aprendizado profundo, que são frequentemente mencionados em conjunto com IA. Essas disciplinas são compostas por algoritmos de IA que buscam criar sistemas especializados que fazem previsões ou classificações com base nos dados de entrada. Basicamente, é a capacidade de aprender com a experiência, e ter a aptidão de resolver problemas, raciocinar, planejar e conceber ideias complexas.

É a ciência e engenharia da criação de máquinas inteligentes, especialmente programas de computação inteligentes. Está relacionado à tarefa semelhante de usar computadores para entender a inteligência humana, mas a IA não precisa se limitar a métodos de observação biológica (McCarthy, 2004).

2.1.1 – Machine Learning

Machine Learning (ML): Ou aprendizado de máquina é um subconjunto da inteligência artificial que se concentra na capacidade de um programa em se adaptar e fazer previsões quando recebe novas informações por meio de algoritmos. Em resumo, o machine learning permite automatizar a análise de padrões complexos nos dados, capacitando o modelo a realizar tarefas específicas. Algoritmos de aprendizado de máquina incluem, a análise de sentimentos, k-means clustering, e regressão linear.

2.1.2 – Redes Neurais

As Redes Neurais Artificiais (RNAs) são motivadas pelo entendimento que o cérebro humano processa as informações de uma forma distinta da arquitetura computacional tradicional (HAYKIN, 2007). Basicamente é um modelo de um algoritmo de aprendizado de máquina, utilizado para reconhecer padrões. É modelado de acordo com a estrutura e função do sistema nervoso central de um animal. Linden (2008) descreve que as redes neurais são inspiradas na natureza que nos cerca. Criaram-se neurônios artificiais extremamente similares aos humanos e interligaram-nos para formar redes que mostraram poder fazer tarefas antes restritas aos cérebros. De modo geral, a rede neural é projetada para se assimilar à forma em que o cérebro humano realiza determinadas tarefas ou funções em áreas de interesse (HAYKIN, 2007).

De acordo com Haykin (2007), as Redes Neurais Artificiais dispõem de propriedades como:

1. Não-linearidade: um Neurônio artificial pode ser ou não linear;
2. Mapeamento de Entrada-Saída: o processo iterativo dos ajustes dos pesos pode ser aplicados de várias formas, eles podem ser classificados como (DOHME, 2003):
 - (a) Aprendizado Supervisionado: quando é utilizado um agente externo que auxilia a rede indicando a saída desejada para determinada entrada;
 - (b) Aprendizado Não Supervisionado (auto-regulação): quando ocorre a ausência de um agente externo;
 - (c) Reforço: quando um “juiz” externo avalia a saída gerada pela rede.
3. Adaptabilidade: capacidade de regular seus pesos sinápticos em função de alterações do seu ambiente;
4. Resposta a Evidências: gera um índice de confiança de suas decisões e análises;
5. Informação Contextual: os neurônios são afetados pela atividade de outros neurônios;
6. Tolerância a Falhas: as redes neurais são robustas contra falhas de neurônios. As RNAs têm como base a utilização dos neurônios artificiais, sendo o neurônio artificial a unidade fundamental da RNA.

2.1.3 – Processamento de linguagem natural

O Processamento de Linguagem Natural (PLN) consiste no desenvolvimento de modelos computacionais para a realização de tarefas que dependem de informações expressas em linguagem natural. O objetivo do PLN é fazer com que os computadores

realizem tarefas úteis que envolvam a linguagem humana, como possibilitar a comunicação homem-máquina, melhorar a comunicação homem-homem ou realizar um processo útil envolvendo texto ou fala (MARTIN; JURAFSKY, 2009).

2.1.4 – Algoritmo de pré-treinamento BERT

O Bert é um algoritmo criado pela Google para otimizar e tornar o sistema de buscas mais assertivo. Já que utiliza da técnica neural chamada PNL para aperfeiçoar a linguagem que os usuários buscam nos meios de busca.

Os modelos típicos que examinam dados textuais de forma linear, da esquerda para a direita ou da direita para a esquerda, diferem do BERT por ser bidirecional. O BERT examina todo o contexto de uma palavra estudando as palavras que vêm antes e depois dela. Este método duplo permite que o BERT compreenda o contexto completo de uma palavra, o que por sua vez aumenta a precisão da análise de sentimento.

O Bidirectional Encoder Representations from Transformers (BERT), foi projetado para pré-treinar representações bidirecionais de textos analisando simultaneamente uma sentença partindo do seu início ao fim e também do fim ao início (DEVLIN et al., 2018).

2.2 – Conceitos de personalização e experiência do usuário

A personalização é o processo de adaptação de produtos, serviços ou conteúdo para atender às necessidades, preferências e interesses específicos de usuários individuais. Isso é feito por meio da análise de dados e do comportamento do usuário, permitindo que as empresas forneçam experiências mais relevantes e significativas para seus clientes. A personalização pode ser aplicada em muitas áreas, como marketing, recomendações de produtos, interface do usuário e atendimento ao cliente.

A experiência do usuário (UX) é o conjunto de percepções, emoções e reações que um usuário experimenta ao interagir com um produto, serviço ou sistema. O objetivo do UX é garantir que os usuários tenham uma experiência positiva e eficaz ao usar um produto ou serviço, levando em consideração aspectos como usabilidade, acessibilidade, desempenho e design. A experiência do usuário é um conceito multidisciplinar que envolve áreas como design de interação, arquitetura da informação, design visual e pesquisa do usuário.

2.2.1 – A importância da personalização na era digital

A personalização na era digital é importante porque permite que as empresas se conectem com os seus clientes de maneira mais eficaz e significativa. A personalização ajuda a criar uma experiência única e relevante para cada usuário, levando em consideração suas preferências, comportamentos e históricos de interação. Alguns exemplos de melhorias com a utilização da personalização.

Maior satisfação do cliente: ao fornecer conteúdo e experiências personalizadas, as empresas podem atender às expectativas e necessidades específicas dos clientes, aumentando assim a satisfação e a fidelidade à marca.

Experiência do usuário aprimorada: a personalização permite que as empresas ajustem suas interfaces, funções e conteúdo para fornecer uma experiência de usuário mais intuitiva e agradável.

Maior engajamento: conteúdos e ofertas personalizados têm maior probabilidade de chamar a atenção dos usuários e incentivá-los a se envolver com a marca, resultando em maior engajamento e engajamento.

Um aumento das conversões e as vendas: a personalização pode ajudar a direcionar os usuários para produtos e serviços mais relevantes para suas necessidades e interesses, aumentando assim as conversões e as vendas.

Análise de dados e percepções: a personalização requer a coleta e análise de dados do usuário que podem fornecer informações valiosas sobre o comportamento, preferências e necessidades de seu público-alvo.

Portanto, a personalização na era digital é fundamental para criar experiências mais agradáveis para os usuários, o que pode levar a uma maior satisfação do cliente.

2.2.2 – Ética e transparência na análise de sentimento

A análise de sentimentos, apesar de ser uma ferramenta poderosa para extrair informações úteis a partir de dados textuais, traz consigo uma série de considerações éticas que devem ser cuidadosamente abordadas. É essencial, portanto, que as empresas e instituições priorizem estes valores para manter a confiança e a credibilidade do público.

É crucial manter padrões éticos e garantir a transparência no tratamento dos dados dos clientes. A confiança do consumidor é estabelecida pelo reconhecimento de que os seus dados são tratados com respeito e utilizados para melhorar a sua experiência, em vez de serem explorados de forma perturbadora.

O uso da inteligência artificial (IA) tornou-se cada vez mais vital na análise dos sentimentos e emoções dos clientes. Ao utilizar análises de texto e voz, as empresas podem obter insights sobre as reações emocionais imediatas de seus clientes, permitindo-lhes adaptar suas interações de acordo. Ao obter feedback dos clientes, as empresas não só aumentam o contentamento do consumidor, mas também obtêm informações valiosas que podem ser usadas para melhorar as suas ofertas de forma consistente.

3. METODOLOGIA

A pesquisa consiste em realizar um estudo experimental exploratório para análise de sentimentos. Utilizamos uma arquitetura específica Transformer. A arquitetura específica implementada para o Transformer foi o BERT, que ficou responsável pela representação vetorial de texto, assim como o aprendizado e a classificação de sentimentos. Foi escolhido uma versão com um menor número de parâmetros e camadas, denominado de *bert-base-uncased*

O desafio central enfrentado é a necessidade de compreender e interpretar as emoções expressas em textos. A complexidade dessa tarefa reside na variedade de formas pelas quais as emoções podem ser expressas linguisticamente, incluindo nuances, sarcasmo e ambiguidades.

3.1 – Etapas do Desenvolvimento




Figura 1 - Etapas do desenvolvimento

3.2 - Escolha do modelo BERT

A escolha do modelo BERT para este projeto foi baseada no desempenho comprovado em tarefas de processamento de linguagem natural (PLN) especificamente em análise de sentimentos. A facilidade de obtenção de suporte disponíveis na comunidade foi outro motivo da escolha. E também pela sua capacidade de lidar com a

complexidade linguística, proporcionar uma base pré-treinada abrangente e oferecer um desempenho sólido em uma variedade de contextos textuais.

3.3 - Pré-Processamento dos dados

3.3.1 - Carregamento do conjunto de dados IMDB

Utilizamos o conjunto de dados da IMDB em sua formatação reduzida, que contém avaliações de filmes classificadas como positivas ou negativas. Os dados são divididos em conjuntos de treinamentos e teste.

Tabela 1. Exemplo de estruturação da base de dados

Textos	Análise	Rótulos
"the movie begins better than and ends funny."	Positivo	1
"This ranks second only to Godzilla as the worst movie I've ever	Negativo	0
"This was the only time I ever walked out on a movie."	Negativo	0
"Enjoyable and watchable. Tim Meadows at his best."	Positivo	1

3.3.2 – Limpeza dos dados

Nesta etapa fazemos a reversão das sequências de inteiros para palavras, usando o índice do vocabulário do conjunto de dados IMDB. A reversão das sequências é uma prática comum para manter a interpretabilidade e a compreensão humana durante as etapas iniciais do processamento de texto, mesmo quando os modelos operam com representações numéricas.

3.3.3 – Tokenização e codificação

Aqui fazemos a tokenização e codificação do modelo de dados. Essa etapa foi crítica para preparar os dados do texto de maneira que modelos como o BERT possam compreender e processar efetivamente a informação contida no texto, capturando relações semânticas e contextualizando as palavras.

A **tokenização** envolve dividir o texto em unidades menores chamadas tokens. No contexto do BERT, os tokens podem ser palavras, subpalavras ou até mesmo partes de palavras.

A **codificação** é o processo de atribuir valores numéricos a cada token. No caso do BERT, essa codificação inclui a atribuição de IDs de token específicos e a criação de

máscaras de atenção para indicar quais partes da sequência são relevantes durante o treinamento.

3.3.4 – Criação do DataLoader

A criação do DataLoader serviu para organizar e fornecer os dados de treinamento em lotes durante o treinamento do modelo BERT. Essa foi uma prática essencial para treinar o modelo eficientemente, melhorar a generalização e simplificar o processo de treinamento, especialmente ao lidar com conjuntos de dados grandes e complexos como o conjunto da IMDB.

3.3.5 – Codificação de Rótulos

A codificação de rótulos foi essencial em meu modelo já que garantiu que os rótulos das classes fossem representados de maneira numérica, garantindo uma padronização das classes em todo o conjunto de dados e tornando-os compatíveis com os requisitos do modelo, facilitando o treinamento eficiente e a avaliação do desempenho.

3.4 – Treinamento do Modelo BERT

Primeiro foi criado um otimizador(optimizer) para ajustar os pesos do modelo, e um scheduler para ajustar dinamicamente a taxa de aprendizado. Em seguida foi definido o número de épocas(epochs) para '3'. Definindo que o treinamento será realizando em três ciclos pelo conjunto de treinamento. Logo após é criada uma função de perda para calcular a discrepância entre as previsões do modelo e os rótulos reais.

O treinamento do modelo BERT é realizado em um loop de épocas, onde cada época consiste em várias iterações sobre o conjunto de treinamento. A quantidade e os tipos de testes apresentaram desafios, haja vista o tempo extremamente extenso para cada iteração de treinamento, validação e teste de um Transformer, o que limita a quantidade de experimentos para este trabalho. O primeiro treinamento com uma (*batch_size = 16*), durou cerca de seis horas. Após completar o treinamento de cada época, o scheduler é acionado para ajustar dinamicamente a taxa de aprendizado.

```

# Crie um otimizador e um scheduler
optimizer = torch.optim.AdamW(bert_model.parameters(), lr=2e-5)
scheduler = torch.optim.lr_scheduler.StepLR(optimizer, step_size=1, gamma=0.9)

# Defina o número de épocas
num_epochs = 2

# Definindo a função de perda
loss_fn = torch.nn.CrossEntropyLoss() #Criação da classe 'CrossEntropyLoss' para calcular a perda durante o treinamento.

# Início do Loop de treinamento que itera sobre cada epoch
for epoch in range(num_epochs):
    bert_model.train() # Indicando que o modelo bert está em modo de train(treinamento).
    for input_ids, attention_mask, targets in train_dataloader: # Função de entrada pro modelo
        optimizer.zero_grad() # Utilizado para zerar os gradientes acumulados dos parâmetros do modelo
        outputs = bert_model(input_ids, attention_mask=attention_mask) # Saída do modelo
        logits = outputs.logits # extração de pontuação antes da aplicação
        loss = loss_fn(logits, targets) # Calculo de perda comparando os preditos('logits') com as classes reais ('targets')
        loss.backward() # é calculado os gradientes em função do modelo
        optimizer.step() # Usado para atualizar os parâmetros com base nos gradientes.

    scheduler.step() # Atualize o scheduler a cada época

```

Figura 2- Exemplo do processo de treinamento

3.5 – Avaliação do Modelo

A avaliação do modelo é realizada no conjunto de teste após o treinamento. Foi definido uma função `evaluate_model` para avaliar o desempenho do modelo. Calculamos métricas de desempenho, como precisão, recall, F1-score e utilizamos uma matriz de confusão para avaliar a capacidade do modelo de realizar previsões precisas. Aqui está uma descrição do processo de avaliação:

4. RESULTADOS E ANÁLISES

4.1 – Desempenho do modelo BERT

O modelo apesar de exigir um significativo período de tempo para o teste, treinamento e validação do conjunto de dados, ficou comprovado que é eficiente, alcançando uma taxa de 0.85% de acurácia e precisão na avaliação de treino, que ainda não é o ideal, mas utilizando apenas 2 epochs e 32 batch-sizes foi o máximo possível alcançado visando a falta de recursos e componentes.

Realizando o cálculo médio, a cada epoch adicionada no modelo, o treinamento tem um aumento em torno de 40 a 50 minutos, isso utilizando uma GPU (Graphics Processing Unit) que é uma unidade de processamento gráfico disponível para aceleração das tarefas do modelo, mas ela é limitada, ou seja, depois de 2 treinamentos tivemos que utilizar uma CPU (Central Processing Unit) que é uma unidade de processamento mais lenta, o que elevou ainda mais o tempo de treinamento.

```
Acurácia: 0.8518393520080999  
Precisão: 0.8552464461031625  
Recall: 0.8518393520080999  
Escore F1: 0.8506147212218907
```

Figura 3 - Resultados das Métricas

A partir da análise da matriz confusão, conseguimos deduzir que o modelo está conseguindo uma taxa relativamente boa em termos de acertos e erros em cada classe. Podemos ver uma taxa significativa de Verdadeiros positivos e Verdadeiros Negativos. E poucos Falsos negativos e Falsos positivos, o que mostra que a acurácia do modelo foi significativamente boa. Essa foi tirada do primeiro treinamento.




Figura 4 - Matriz Confusão

4.2 - Avaliação de Impacto na Experiência do Usuário

Esse sistema de análise pode compreender diversos contextos em textos, significando que pode entender sentimentos complexos e fornecer uma resposta mais

alinhada com a intenção do usuário. Com o aperfeiçoamento desse modelo, podemos personalizar interações com os usuários de forma mais eficaz.

A capacidade de identificar sentimentos negativos de forma eficiente permite uma detecção mais rápida de problemas ou insatisfações dos usuários. Possibilitando ações proativas para resolver problemas antes que impactem negativamente a experiência do usuário.

5. CONSIDERAÇÕES FINAIS

Neste trabalho foi executado um projeto de uma deep learning com a arquitetura profunda de uma rede neural artificiais (BERT) com processamento de linguagem natural, com o foco na análise de sentimentos, e como isso está impactando na personalização e experiência do usuário.

Todos os objetivos gerais e específicos propostos foram cumpridos. Com este modelo será possível extrair informações sobre a análise de sentimentos de diferentes fontes de textos, e utiliza-lo para aplicações do mundo real.

Importante ressaltar que embora a análise de sentimentos ofereça valiosas percepções sobre a experiência do usuário, é imprescindível a ética e a transparência para se lidar com dados sensíveis de usuários mantendo a ética de trabalho contínua.

O modelo do BERT está cada vez mais refinado e aprimorado, e podemos esperar grandes avanços no futuro, o que abre a possibilidade de trabalhos futuros utilizando um conjunto de dados mais extensos para uma análise mais eficaz.

REFERÊNCIAS

- SYOZI, Ricardo.** O que é deep learning? **Tecnoblog**, 2022. Disponível em: <https://tecnoblog.net/responde/o-que-e-deep-learning/>. Acesso em: 07 jun. 2023.
- EXPERIÊNCIA do usuário: o guia completo para agradar seu público digital em 2023. **Rockcontent**, 2020. Disponível em: <https://rockcontent.com/br/blog/experiencia-do-usuario/>. Acesso em: 06 jun. 2023.
- SPADINI, Allan.** O que é inteligência Artificial? Como funciona uma IA, quais os tipos e exemplos. **Alura**, 2023. Disponível em: https://www.alura.com.br/artigos/inteligencia-artificial?gclid=CjwKCAjwm4ukBhAuEiwA0zQxk_2wgH5pTapnNsn4yKKgluqfgyp5fwXimUUC5Cw0xO8T4Xe7Py-4rBoCqNQQAvD_BwE. Acesso em 04 jun. 2023
- LINDEN, Ricardo. **Algoritmos genéticos, uma importante ferramenta da Inteligência Computacional**. 2ª Edição. Rio de Janeiro: Brasport, 2008.
- GOMES, Gustavo.** Como a inteligência artificial pode transformar a experiência do cliente. **Agendor**, 2023. Disponível em: <https://www.agendor.com.br/blog/como-inteligencia-artificial-pode-transformar-experiencia-cliente/>. Acesso em: 02 jun. 2023.
- PALIS, André.** Como a inteligência artificial ajuda na experiência do usuário? **Tecmundo**, 2023. Disponível em: <https://www.tecmundo.com.br/internet/216871-inteligencia-artificial-ajuda-experiencia-usuario.htm>. Acesso em: 07 mai. 2023
- MCCARTHY, John. WHAT IS ARTIFICIAL INTELLIGENCE?. **Computer Science Department**, Stanford University, nov/12. 2007. Disponível em: <https://www-formal.stanford.edu/jmc/whatisai.pdf>. Acesso em: 20 set. 2023.
- DOHME, V. D. **Atividades lúdicas na educação: o caminho de tijolos amarelos do aprendizado**. [S.l.]: Vozes, 2003.
- DEVLIN, J.; CHANG, M.-W.; LEE, K.; TOUTANOVA, K. Bert: Pre-training of deep bidirectional transformers for language understanding. **arXiv preprint arXiv:1810.04805**, 2018. Acesso em 20 out. 2023.
- HAYKIN, S. **Redes neurais: princípios e prática**. [S.l.]: Bookman Editora, 2007.
- MARTIN, J. H.; JURAFSKY, D. **Speech and language processing: An introduction to natural language processing, computational linguistics, and speech recognition**. [S.l.]: Pearson/Prentice Hall Upper Saddle River, 2009.
- YANAGUYA, Renata Tiemi. Estudo de caso: Mineração de dados em sistemas para internet. **SISTEMAS PARA INTERNET**, São João da Boa Vista. 2012. Disponível em: <https://normas-abnt.espm.br/index.php?title=Artigo>. Acesso em: 08 nov. 2023.

LACERDA, Larissa. Tudo sobre o BERT: o novo algoritmo do Google que promete revolucionar as SERPs. **Rockcontent**, 2020. Disponível em: <https://rockcontent.com/br/blog/bert/>. Acesso em 20 nov. 2023.

APRENDA tudo sobre o conceito de Inteligência Artificial (IA). **Tableau**, 2023. Disponível em: <https://www.tableau.com/pt-br/learn/articles/ai#:~:text=A%20Intelig%C3%Aancia%20Artificial%20%C3%A9%20a,que%20recebem%20de%20seus%20usu%C3%A1rios>. Acesso em: 01 jun. 2023.

TANTSIURA, Pavel. What is Sentiment Analysis: Definition, Key Types and Algorithms, 2023. Disponível em: <https://theappsolutions.com/blog/development/sentiment-analysis/>. Acesso em: 20 nov. 2023.

TOKUDA, H. O. Nivaldo; COELHO, B. Orlando; ARAUJO, M. Renata. Análise de Sentimento por meio de Deep Learning aplicada à Mineração de Argumentos **Computação e Informática**, São Paulo. Disponível em: <https://adelpha-api.mackenzie.br/server/api/core/bitstreams/8703b0b7-64db-4693-b629-06fecf64ab2b/content>. Acesso em: 28 nov. 2023.